

OAT 2 – Mecânica BELÉM

Autores: Érica Araujo

Mickael Cedraz Alencar

Monyc Luisa Almeida de Cerqueira

Nalbert de Souza Santana

Pedro César Paixão de Jesus

Rafael Santos da Silva

Agenda

O objetivo desta apresentação é mostrar quais previsões simples representam melhor a demanda de óleo e motor, quanto elas erram e como essa avaliação orienta o desenvolvimento da solução para as oficinas.

1. Contexto:

A empresa e a necessidade das oficinas.

2. Dados e Baselines:

Preparação, exploração das séries e regras de previsão.

3. Validação e métricas:

Divisão temporal e cálculo dos erros.

4. Resultados:

Comparação dos baselines para óleo e motor.

5. Features temporais:

Criação de atributos a partir do histórico.

6. Considerações finais:

Principais resultados e aprendizados.

QUEM SOMOS

- A MecâniQA é uma empresa de tecnologia automotiva voltada a oficinas e auto centers de Feira de Santana e região.

O DESAFIO

- A demanda varia entre os dias: picos provocam falta de peças, enquanto períodos de baixa deixam mecânicos ociosos.

A NECESSIDADE

- Antecipar a procura por serviços para planejar peças, insumos e disponibilidade de mecânicos.

- Demanda diária de trocas de óleo e manutenção de motor (janeiro de 2024 a dezembro de 2025).
- Histórico preenchido com o último valor disponível.
- Alvos ausentes são preservados para exclusão na avaliação.

Tratar os dados

```
df["Trocas_Oleo"] = df["Trocas_Oleo"].clip(upper=55)
df["Manutencao_Motor"] = df["Manutencao_Motor"].clip(lower=0, upper=26)

# Guarda os valores observados, inclusive os que estão ausentes.
observado = df.copy()

# Preenche o histórico usando somente valores anteriores.
df = df.ffill()
df.isna().sum()
```

```
Trocas_Oleo      0
Manutencao_Motor  0
dtype: int64
```

Como construímos as previsões


- Naive: repete o valor anterior.
- Médias móveis: usam os últimos 7 ou 30 dias.
- O **shift(1)** impede que o valor do próprio dia entre na previsão.

Criar os baselines


In [9]:

```
def modelo_naive(serie):  
    return serie.shift(1)  
  
def modelo_media_movel(serie, janela):  
    return serie.shift(1).rolling(janela).mean()
```


Previsões de trocas de óleo



Previsões de manutenção de motor



Exploração temporal



Validação Temporal



- Cinco divisões cronológicas: o histórico cresce e o teste permanece depois do treino.
- Avaliação de um dia à frente, com atualização diária do histórico.

```
tscv = TimeSeriesSplit(n_splits=5)

for treino, teste in tscv.split(df):
    print(f"Treino até {df.index[treino[-1]].date()} | "
          f"Teste: {df.index[teste[0]].date()} a {df.index[teste[-1]].date()}")
```

Treino até 2024-05-05		Teste: 2024-05-06 a 2024-09-03
Treino até 2024-09-03		Teste: 2024-09-04 a 2025-01-02
Treino até 2025-01-02		Teste: 2025-01-03 a 2025-05-03
Treino até 2025-05-03		Teste: 2025-05-04 a 2025-09-01
Treino até 2025-09-01		Teste: 2025-09-02 a 2025-12-31

Métricas e Resultados

- MAE: erro absoluto médio
- RMSE: maior peso para erros grandes
- MAPE: erro percentual
- Pelo menor MAE: Naive para óleo (6,65) e média de 30 dias para motor (3,21).
- Média dos cinco períodos. Valores reais iguais a zero são excluídos apenas do MAPE.

```
resumo.round(2)
```

Out[7]:

	Serie	Modelo	MAE	RMSE	MAPE
5	Manutencao_Motor	Media_30	3.21	3.82	43.80
4	Manutencao_Motor	Media_7	3.25	3.87	44.30
3	Manutencao_Motor	Naive	3.43	4.46	43.55
0	Trocas_Oleo	Naive	6.65	8.92	32.64
2	Trocas_Oleo	Media_30	7.34	8.15	37.31
1	Trocas_Oleo	Media_7	7.36	8.09	37.22

- Para cada serviço: valores de 1, 7 e 30 dias atrás e média dos 7 dias anteriores.

Criar os lags e a média móvel

In [5]:

```
df_features = pd.DataFrame(index=df.index)

for coluna in colunas:
    df_features[f"{coluna}_lag_1"] = df[coluna].shift(1)
    df_features[f"{coluna}_lag_7"] = df[coluna].shift(7)
    df_features[f"{coluna}_lag_30"] = df[coluna].shift(30)

    df_features[f"{coluna}_media_7"] = (
        df[coluna].shift(1).rolling(7).mean()
    )
```

Bases Geradas



- Duas bases exportadas: 8 atributos temporais e 1 alvo em cada uma
- Óleo: 695 registros. Motor: 698 registros. A data é mantida como índice.

Base de óleo: (695, 9)

Base de motor: (698, 9)

Considerações finais



- A comparação mostrou que o desempenho dos baselines varia conforme o serviço e a métrica utilizada.
- Pelo MAE, o Naive apresentou menor erro para trocas de óleo (6,65), enquanto a média móvel de 30 dias apresentou menor erro para manutenção de motor (3,21).
- Esses resultados reforçam a importância de considerar os erros das previsões ao utilizá-las como apoio ao planejamento das oficinas.

Referências

- BELÉM (Equipe). ***mecaniQA-belem***. GitHub, 2026. Disponível em: Repositório da equipe. Acesso em: 22 set. 2026.
- MECÂNICA AUTOMOTIVE TECH. ***OAT 2 — Baseline e Métricas de Avaliação***. Programa de Trainee 2026.2, 2026. Material da disciplina.
- PANDAS. ***Documentação: séries temporais e janelas móveis***. Disponível em: Time series / date functionality e Window. Acesso em: 22 set. 2026.
- SCIKIT-LEARN. ***Documentação: validação temporal e métricas de avaliação***. Disponível em: TimeSeriesSplit e Metrics and scoring. Acesso em: 22 set. 2026.
- STATSMODELS. ***seasonal_decompose: decomposição sazonal***. Disponível em: Documentação de seasonal_decompose. Acesso em: 22 set. 2026.
- MATPLOTLIB. ***matplotlib.pyplot: documentação***. Disponível em: Documentação de pyplot. Acesso em: 22 set. 2026.